

Machine Learning e MLP na Classificação

Fundamentos da MLP

Trata-se de uma rede neural com uma ou mais camadas ocultas com um número indeterminado de neurônios. A camada oculta possui esse nome porque não é possível prever a saída desejada nas camadas intermediárias.

MLP Architecture:

Camada de entrada, camada oculta e camada de saída.

1. Input layer

- A mesma quantidade de variáveis que compõem uma entrada do problema.

Exemplo: RN para classificar nível de colesterol.

- Variáveis por entrada: sexo, idade, IMC, classe social, alimentação de risco
- Neurônios sensoriais: 5

2. Output Layer

- Um neurônio por classe: o valor de saída de cada neurônio será a probabilidade de a entrada pertencer aquela classe.

Exemplo: classe de colesterol > **normal, alto, médio.**

- Neurônios na camada de saída: 3

3. Hidden Layer

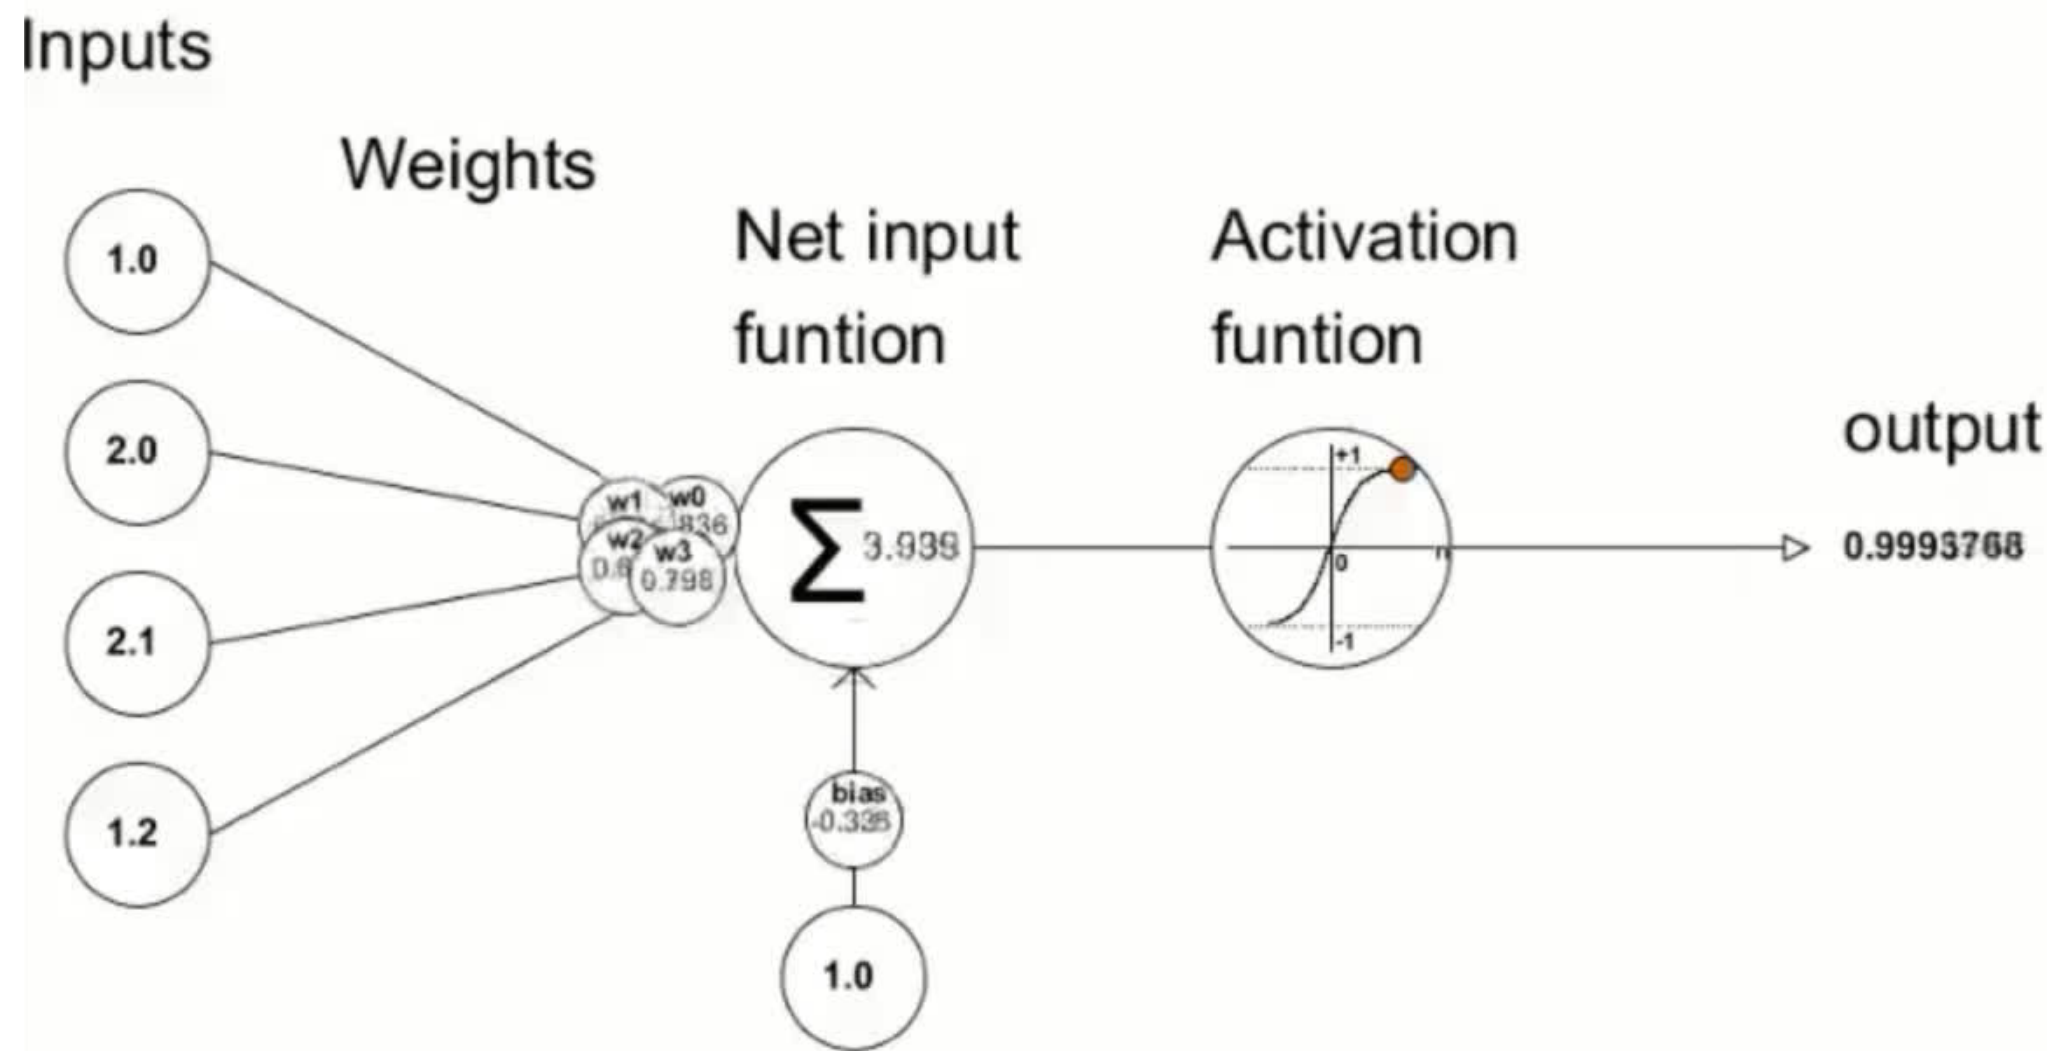
- Seguir o princípio da Navalha de Ockha: Se houver opções equivalentes, preferir a mais simples

—Treinar RNs com diferentes quantidades de camadas ocultas e neurônios nestas camadas.

—Verificar a capacidade de generalização (taxa de acertos) de cada RN.

— Adotar a mais simples

Backpropagation



Na etapa final, um ***error*** é calculado. Nosso objetivo é reduzir o erro, e a única opção que temos é ajustar os pesos. Para isso, utilizamos um algoritmo chamado "***backpropagation***."

Diferentemente do Perceptron e Adaline, onde existe apenas um único neurônio de saída {y}, a MLP pode relacionar o conhecimento a vários neurônios de saída.

O algoritmo de aprendizado (backpropagation), é composto de 4 passos:

1º Passo: Inicialização

- Atribuir valores aleatórios para os pesos e limites
- Escolha dos valores iniciais influencia o comportamento da rede
- Na ausência de conhecimento prévio os pesos e limites devem ter valores iniciais aleatórios e pequenos uniformemente distribuídos

2º Passo: Ativação

- Calcular os valores dos neurônios da camada oculta
- Calcular os valores dos neurônios da camada de saída

3º Passo: Treinar os Pesos

- Calcular os erros dos neurônios das camadas de saída e oculta
- Calcular a correção dos pesos
- Atualizar os pesos dos neurônios das camadas de saída e oculta

4º Passo: Iteração

- Repetir o processo a partir do passo 2 até que satisfaça o critério de erro

Versatilidade da MLP

- **Adaptação a Complexidade:** MLP é capaz de lidar com problemas de classificação simples e complexos, ajustando-se dinamicamente à complexidade dos dados.
- **Multiclasses:** Enfatiza a habilidade da MLP de lidar com problemas de classificação multiclasses, tornando-a adequada para diversas aplicações.